# Lenguaje SQL



# Introducción

**SQL**, que significa "Structured Query Language" (Lenguaje de Consulta Estructurado), es un lenguaje de programación utilizado para gestionar y manipular bases de datos relacionales. Fue desarrollado en la década de 1970 en IBM basándose en el trabajo de Edgard Codd y se ha convertido en el estándar de facto para interactuar con sistemas de gestión de bases de datos relacionales (SGBDR).

La primera versión de SQL normalizada por ANSI data de 1986. La norma SQL2 o SQL92 es la más importante y la mayoría de los SGBDR existentes implementan esta versión.

Características clave de SQL:

- Declarativo: SQL es un lenguaje de programación declarativo, lo que significa que describe el resultado deseado sin
  especificar el método para alcanzarlo. Esto permite a los usuarios centrarse en lo que quieren obtener, en lugar de cómo
  lograrlo.
- **Gestión de datos relacional**: SQL se utiliza principalmente en entornos de bases de datos relacionales, donde la información se organiza en tablas con relaciones entre ellas. Esto facilita la gestión y recuperación eficiente de datos.
- Manipulación de datos: SQL permite realizar operaciones fundamentales sobre datos, como la inserción (INSERT), la actualización (UPDATE), la eliminación (DELETE), y la recuperación (SELECT) de información de la base de datos.
- Creación y modificación de estructuras de datos: SQL también se utiliza para definir y modificar la estructura de las bases de datos, mediante la creación de tablas (CREATE TABLE), la alteración de tablas (ALTER TABLE), y la eliminación de tablas (DROP TABLE).
- Consulta de datos: La sentencia SELECT es esencial en SQL y se utiliza para recuperar datos de una o varias tablas. Permite filtrar, ordenar y agrupar información según las necesidades del usuario.
- Integridad de datos: SQL garantiza la integridad de los datos mediante restricciones como claves primarias, claves foráneas y otros mecanismos que aseguran la consistencia y fiabilidad de la información almacenada.
- **Transacciones**: SQL ofrece soporte para transacciones, permitiendo agrupar varias operaciones en una unidad atómica. Esto asegura que todas las operaciones se realicen con éxito o ninguna de ellas.

SQL se ha convertido en una herramienta esencial para cualquier persona involucrada en el desarrollo de software, administración de bases de datos, análisis de datos y otras disciplinas relacionadas con el manejo de información estructurada. Con su amplia adopción, el conocimiento de SQL es valioso en diversos contextos profesionales.

El lenguaje SQL se divide en cuatro subconjuntos:

- **DDL** (*Data Definition Language*), que agrupa todos los comandos utilizados para crear, modificar o eliminar las estructuras de la base de datos (tablas, índices, vistas, etc.). Se trata principalmente de los comandos:
  - o CREATE
  - o ALTER
  - o DROP

- **DML** (*Data Manipulation Language*), que agrupa los comandos utilizados para manipular los datos contenidos en la base de datos. Se trata principalmente de los comandos:
  - SELECT
  - o INSERT
  - DELETE
  - UPDATE
- **DCL** (*Data Control Language*), que agrupa los comandos utilizados para administrar la seguridad de acceso a los datos. Se trata principalmente de los comandos:
  - o GRANT
  - REVOKE
- TCL (*Transaction Control Language*), que agrupa los comandos utilizados para administrar la confirmación o no de actualizaciones realizadas sobre la base de datos. Se trata principalmente de los comandos:
  - o COMMIT
  - o ROLLBACK

▲ Sección introductoria generada por ChatGPT

# Modelo relacional

El modelo relacional fue creado por **Edgar Codd**, un investigador que trabajaba en IBM a principios de los años 70. Su trabajo pionero, "*A Relational Model of Data for Large Shared Data Banks*", sentó las bases de este modelo.

El modelo relacional se basa en el concepto de **conjunto**. Esquemáticamente, el modelo relacional se puede representar a través de una **tabla**, que en términos relacionales es una representación de una relación. Cada fila en la tabla corresponde a una **tupla** (o registro), y cada columna representa un **atributo**.

En el modelo relacional, el término **relación** se utiliza para referirse a una tabla, mientras que el término **tupla** se utiliza para referise a una fila. De forma similar, el término **atributo** se refiere a una columna de la tabla.

Este modelo presenta los datos de forma lógica, independientemente del modelo físico. El proveedor de la base de datos decide el modo de almacenamiento físico de las tablas. Esta independencia entre lo lógico y lo físico es una de las mayores ventajas de las bases de datos relacionales.

Una vez definidas las tablas, es necesario un lenguaje para manipularlas, lo cual se logra a través del **álgebra relacional**. Este formalismo matemático permite realizar operaciones sobre conjuntos de datos, como selecciones, proyecciones y uniones.

**SQL** implementa el álgebra relacional, y los sistemas de gestión de bases de datos relacionales (SGBDR) son los encargados de implementar el modelo relacional en la práctica.

El objeto principal gestionado por el modelo relacional es la **relación**, que está asociada a los conceptos de **dominio** y de **atributo**.

A esta relación se le aplican reglas:

• **Coherencia**: los datos en cualquier columna deben pertenecer al tipo definido por el dominio de ese atributo. La coherencia se asegura cuando cada valor pertenece al dominio sobre el que está definido el atributo.

- Unicidad de las filas: no pueden existir dos tuplas (filas) idénticas dentro de una misma relación (tabla). Cada tupla debe ser única.
- Aceptación de valores nulos: el concepto de valor nulo es válido y representa datos desconocidos o inaplicables en una columna.
  - **Restricción de entidad**: cualquier valor que forme parte de una clave primaria debe ser diferente de NULL, ya que las claves primarias deben identificar de manera única cada fila.
- Atomicidad de los valores: Los datos almacenados en cada columna de una tabla deben ser atómicos (monovalorados).
   Es decir, cada valor no puede ser dividido en valores más pequeños. Esto garantiza que la relación esté normalizada.

#### · Independencia del orden

- El orden de los atributos (columnas) en una relación no tiene importancia.
- El orden de las tuplas (filas) tampoco importa; las tuplas no están ordenadas.

#### Nombre único:

- o Cada columna de una relación debe tener un nombre único dentro de esa tabla.
- o Cada relación (tabla) debe tener un nombre específico y diferente al resto de las relaciones en la base de datos.
- Identificador: atributo o conjunto de atributos que permiten caracterizar de forma unívoca cada elemento de la relación.
  - Clave primaria: identificador mínimo de una relación, que asegura la unicidad de cada tupla. Por ejemplo, en una tabla clientes, el campo id\_cliente puede ser la clave primaria.
  - Clave secundaria: otros atributos que también pueden identificar de manera única una tupla, pero no son el identificador principal. Un ejemplo podría ser el nif de un cliente en la misma tabla clientes.
- **Integridad referencial**: esta regla impone que un atributo o conjunto de atributos de una relación aparezca como clave primaria en otra relación. Esto garantiza que las relaciones entre tablas sean válidas y consistentes.
  - Clave externa: atributo o conjunto de atributos que referencia la clave primaria de otra tabla, asegurando la integridad referencial. Por ejemplo, en una tabla pedidos, el campo id\_cliente puede ser una clave externa que referencia a la clave primaria id\_cliente en la tabla clientes.

### **Dominio**

El dominio es el **conjunto de posibles valores** que un atributo puede tomar, representado por un nombre. Por ejemplo, el atributo edad en una tabla de personas puede tener como dominio el conjunto de números enteros positivos (edad ≥ 0). Si otro atributo es nombre, el dominio puede ser el conjunto de todas las cadenas de texto válidas.

Si tenemos un atributo estado civil, su dominio podría ser {"soltero", "casado", "divorciado", "viudo"}.

#### Cardinalidad

El número de elementos en un dominio se denomina **cardinalidad**. En el ejemplo anterior, la cardinalidad del dominio estado civil es 4.

## Relación

Una relación definida sobre los dominios D1, D2, ..., Dn es un subconjunto del producto cartesiano de estos dominios, caracterizado por un nombre. En términos prácticos, una **relación se representa como una tabla** en una base de datos

relacional.

Una tabla personas puede ser una relación sobre los dominios nombre, edad y estado civil, donde cada fila (tupla) representa una persona.

#### **Atributo**

Un atributo es una columna de la relación, caracterizada por un nombre. Cada atributo está asociado con un dominio que define los valores posibles para esa columna.

En la relación personas , los atributos podrían ser nombre , edad y estado civil .

#### Grado

En una relación, el grado es el número de atributos que tiene. Dicho de otro modo, el número de columnas de una tabla.

Si la tabla personas tiene los atributos nombre, edad y estado civil, entonces el grado de la relación es 3.

# Álgebra relacional

El **álgebra relacional** es un conjunto de operaciones que permite extraer y manipular datos de bases de datos relacionales. Se basa en **la teoría de conjuntos** y permite combinar, filtrar y transformar tablas (relaciones) existentes para generar nuevas tablas de resultados. Estos resultados pueden ser usados de **manera inmediata** o como base para otras operaciones.

Los operadores fundamentales basados en la teoría de conjuntos:

- Selección (σ): Este operador se usa para filtrar filas de una tabla que cumplen una condición específica. El resultado es un subconjunto de la tabla original.
- Proyección (π): este operador selecciona columnas específicas de una tabla, eliminando las columnas que no son necesarias en la nueva tabla de resultados.
- Unión (U): combina las filas de dos tablas que tienen la misma estructura (mismo número de columnas y dominios compatibles). La tabla de resultado contiene todas las filas de ambas tablas, eliminando duplicados.
- Intersección (n): devuelve las filas que son comunes a dos tablas que tienen la misma estructura.
- Diferencia (-): Devuelve las filas que están en la primera tabla, pero no en la segunda, para tablas con la misma estructura.
- Combinación (M): combina las filas de dos tablas basándose en una condición que involucra una o más columnas de cada tabla. Existen diferentes tipos de join:
  - Theta Join (θ): combina tablas usando una condición cualquiera.
  - Equijoin: un tipo específico de join donde las columnas relacionadas deben tener valores iguales.
  - Natural Join: Similar al equijoin, pero elimina las columnas repetidas en las tablas relacionadas.

# Selección (σ)

La selección (σ) es una operación del álgebra relacional que permite extraer filas (tuplas) de una relación (tabla) que cumplen con una condición específica. La tabla resultante tendrá la misma estructura (número de columnas y dominios) que la relación original, pero solo contendrá las filas que satisfacen el criterio de selección.

La notación es  $Rx = \sigma(condición)(R)$ , donde R es la relación de la cual se realiza la selección y Rx es la nueva relación resultante.

Por ejemplo, si tenemos una tabla CLIENTES y deseamos seleccionar todos los clientes que pertenecen a la región "Centro":

#### Tabla CLIENTES

ID	Nombre	Región
1	Juan Pérez	Centro
2	Ana Gómez	Oeste
3	Luis Rodríguez	Centro
4	Marta López	Este
5	Carlos Ruiz	Oeste
6	Laura Sánchez	Centro

Esta operación se expresa como CLIENTES\_CENTRO =  $\sigma(región = "Centro")(CLIENTES)$ . Esto generará una nueva tabla CLIENTES\_CENTRO que incluirá únicamente las filas de CLIENTES donde la columna región tiene el valor "Centro".

#### • Resultado: CLIENTES\_CENTRO = $\sigma(región = "Centro")(CLIENTES)$

ID	Nombre	Región
1	Juan Pérez	Centro
3	Luis Rodríguez	Centro
6	Laura Sánchez	Centro

El término "selección" del álgebra relacional tiene un **significado diferente** del que se utiliza en SQL, que resulta de un hecho histórico desafortunado. En álgebra relacional, el término "selección" corresponde a lo que en SQL se denomina **where**.

# Proyección (π)

La **proyección** (π) es una operación del álgebra relacional que permite **extraer columnas específicas de una relación**, generando así una nueva relación que contiene únicamente los atributos seleccionados. Este operador es útil cuando se desea obtener una vista reducida de los datos, centrándose solo en los atributos relevantes.

La notación es  $Rx = \pi(A1, A2, ..., An)(R)$ , donde A1, A2, ..., An son los atributos a proyectar, R es la relación de la cual se realiza la proyección y Rx es la relación resultante.

La operación de proyección no solo reduce la cantidad de datos visualizados, sino que también elimina duplicados en los resultados, asegurando que cada combinación de valores de las columnas proyectadas sea única.

Por ejemplo, dada la tabla CLIENTES, si queremos extraer únicamente los nombres y las regiones de los clientes, aplicaríamos la proyección de la siguiente manera:

### • Tabla CLIENTES

Nombre	Región
Juan Pérez	Centro
Ana Gómez	Oeste
Luis Rodríguez	Centro
Marta López	Este
Carlos Ruiz	Oeste
Laura Sánchez	Centro
	Juan Pérez Ana Gómez Luis Rodríguez Marta López Carlos Ruiz

• **Resultado**: CLIENTES\_NOMBRES\_REGIONES = π(Nombre, Región)(CLIENTES)

Nombre	Región
Juan Pérez	Centro
Ana Gómez	Oeste
Luis Rodríguez	Centro
Marta López	Este
Carlos Ruiz	Oeste
Laura Sánchez	Centro

# Unión (∪)

La unión (U) es una operación del álgebra relacional que permite combinar dos relaciones para obtener una nueva relación que contenga todos los elementos distintos de ambas, eliminando duplicados. Esta operación solo es válida para relaciones que tienen la misma estructura, es decir, deben tener el mismo número de columnas (mismo grado) y los mismos dominios para cada columna.

La notación es  $Rx = R1 \cup R2$ , donde Rx es la nueva relación resultante.

La operación de unión es útil en la manipulación de bases de datos para consolidar información de diferentes fuentes o categorías. Por ejemplo, puede ser utilizada para combinar listas de clientes de diferentes regiones o periodos de tiempo en una sola lista.

Por ejemplo, dadas dos tablas diferentes CLIENTES\_OESTE y CLIENTES\_CENTRO, la unión puede representarse como CLIENTES = CLIENTES\_OESTE U CLIENTES\_CENTRO y contendrá todas las filas de ambas tablas, eliminando los duplicados y proporcionando un conjunto de clientes que pertenecen a cualquiera de las dos regiones.

## • Tabla CLIENTES\_OESTE

ID	Nombre	Región
1	Juan	Oeste
2	María	Oeste
3	Pedro	Oeste

#### • Tabla CLIENTES\_CENTRO

ID	Nombre	Región
3	Pedro	Centro
4	Laura	Centro
5	Elena	Centro

# • Resultado: CLIENTES = CLIENTES\_OESTE ∪ CLIENTES\_CENTRO

ID	Nombre	Región
1	Juan	Oeste
2	María	Oeste
3	Pedro	Oeste
3	Pedro	Centro
4	Laura	Centro
5	Elena	Centro

Otra aplicación sería, por ejemplo, utilizar la selección sobre una misma tabla. Como ya se ha comentado, aplicar un operador de álgebra relacional genera una tabla resultante que puede ser utilizada. Por lo tanto, aplicar dos selecciones sobre una tabla genera dos tablas resultantes.

Dada la tabla CLIENTES queremos seleccionar los clientes de la región "Centro" y "Oeste":

# • Tabla CLIENTES

ID	Nombre	Región
1	Juan Pérez	Centro
2	Ana Gómez	Oeste
3	Luis Rodríguez	Centro
4	Marta López	Este
5	Carlos Ruiz	Oeste
6	Laura Sánchez	Centro

# • Resultado: CLIENTES = $\sigma(región = "Centro")(CLIENTES) \cup \sigma(región = "Oeste")(CLIENTES)$

ID	Nombre	Región
1	Juan Pérez	Centro
2	Ana Gómez	Oeste
3	Luis Rodríguez	Centro

ID	Nombre	Región
5	Carlos Ruiz	Oeste
6	Laura Sánchez	Centro

# Intersección (∩)

La intersección (n) es una operación del álgebra relacional que permite obtener el conjunto de elementos que son comunes a dos relaciones. Esta operación solo es válida para relaciones que tienen la misma estructura, es decir, deben tener el mismo número de columnas (mismo grado) y los mismos dominios para cada columna.

La notación es Rx = R1 n R2, donde Rx es la nueva relación resultante.

La operación de intersección es útil en la manipulación de bases de datos para encontrar elementos que comparten características específicas en dos conjuntos diferentes. Por ejemplo, puede ser utilizada para identificar clientes que han realizado compras en dos diferentes periodos o categorías.

Por ejemplo, dadas las tablas CLIENTES\_OESTE y CLIENTES\_CENTRO la intersección puede representarse como CLIENTES = CLIENTES\_OESTE o CLIENTES\_CENTRO y contendrá todas las filas de ambas tablas, eliminando los duplicados y proporcionando un conjunto de clientes que pertenecen a las dos regiones.

#### • Tabla CLIENTES\_OESTE

ID	Nombre	Región
1	Juan	Gijón
2	María	Zamora
3	Pedro	Mérida

#### • Tabla CLIENTES\_CENTRO

ID	Nombre	Región
3	Pedro	Mérida
4	Laura	Madrid
5	Elena	Toledo

#### • Resultado: CLIENTES = CLIENTES\_OESTE n CLIENTES\_CENTRO

ID	Nombre	Región
3	Pedro	Mérida

Es importante notar que, aunque la intersección es una operación válida y útil en álgebra relacional, algunos textos mencionan que su función se puede expresar usando el operador diferencia. Es decir, si queremos encontrar los elementos comunes entre dos relaciones, podemos calcularlo utilizando la diferencia de cada relación con la unión de ambas, lo que puede hacer que la intersección sea conceptualmente redundante en algunos contextos.

La fórmula para expresar esto sería: R1 n R2 = R1 - (R1 - R2)

# Diferencia (-)

La diferencia (-) es una operación del álgebra relacional que permite obtener una nueva relación al eliminar de una relación (R1) los elementos que también están presentes en otra relación (R2). Esta operación solo es válida para relaciones que tienen la misma estructura, es decir, deben tener el mismo número de columnas (mismo grado) y los mismos dominios para cada columna.

La notación para la diferencia es Rx = R1 - R2, donde Rx es la nueva relación resultante.

La operación de diferencia es útil para identificar elementos que son exclusivos de una relación y que no están presentes en otra. Por ejemplo, puede ser utilizada para encontrar clientes que no han realizado compras en un periodo determinado.

Por ejemplo, dada la tabla CLIENTES, queremos seleccionar aquellos clientes existentes en el año 2022 pero que ya no son clientes en 2023:

Tabla CLIENTES

# Tabla CLIENTES

ID	Nombre	Región	Año
1	Juan Pérez	Centro	2022
2	Ana Gómez	Oeste	2022
3	Luis Rodríguez	Centro	2022
4	Marta López	Este	2022
3	Luis Rodríguez	Oeste	2023
6	Laura Sánchez	Centro	2023
7	Elena Torres	Oeste	2023

• Resultado: CLIENTES =  $\sigma(a\tilde{n}o$  = 2022)(CLIENTES) -  $\sigma(a\tilde{n}o$  = 2023)(CLIENTES)

ID	Nombre	Región	Año
1	Juan Pérez	Centro	2022
2	Ana Gómez	Oeste	2022
4	Marta López	Este	2022

En 2022, los clientes con ID 1, 2 y 4 están registrados, mientras que en 2023 no están presentes, lo que los convierte en clientes exclusivos de 2022.

# Restricción

TODO

# Proyección

TODO

## Producto cartesiano

El **producto cartesiano** P entre varios dominios D1, D2, ..., Dn, se expresa como P = D1 x D2 x ... x Dn. Este producto representa todas las **combinaciones posibles** de los valores en esos dominios.

Si tenemos dos dominios D1={1,2} y D2={"A", "B"}, el producto cartesiano de D1 y D2 sería:

```
• P = {(1, "A"), (1, "B"), (2, "A"), (2, "B")}
```

Cada par de valores es una tupla (d1, d2), donde "d1" proviene de D1 y "d2" proviene de D2. Este concepto es clave para entender cómo las bases de datos combinan múltiples tablas (relaciones) mediante operaciones como el **join**.

Si tenemos tres dominios D1 = {1, 2}, D2 = {"A", "B"} y D3 = {X, Y}, el producto cartesiano sería:

```
• P = {(1, "A", X), (1, "A", Y), (1, "B", X), (1, "B", Y), (2, "A", X), (2, "A", Y), (2, "B", X), (2, "B", Y)}.
```

# **Combinaciones**

TODO

## SQL

TODO

# **Práctica**

# MySQL en Docker con persistencia

# Creación del contenedor

```
# Crear el contenedor
docker run --name mysql-container -e MYSQL_ROOT_PASSWORD=tu_contraseña -e MYSQL_DATABASE=mi_base_de_datos -v mysql_data:
# Comprobar que el contenedor está corriendo
docker ps
```

- --name mysql-container: Nombre del contenedor.
- -e MYSQL\_ROOT\_PASSWORD=tu\_contraseña : Establece la contraseña para el usuario root.
- -e MYSQL\_DATABASE=mi\_base\_de\_datos : Crea una base de datos inicial llamada mi\_base\_de\_datos.
- -v mysql\_data:/var/lib/mysql: Crea un volumen llamado mysql\_data para persistir los datos.
- -p 3306:3306 : Expone el puerto 3306 (puerto predeterminado de MySQL) para conectarte desde tu máquina.
- -d mysql:latest: Utiliza la imagen más reciente de MySQL y ejecuta el contenedor en segundo plano.

#### Conectarse al contenedor

1. Conectarse desde cualquier cliente MySQL usando localhost:3306, el usuario root y la contraseña configurada.

2. Conectarse al contenedor de MySQL desde la terminal:

```
docker exec -it mysql-container mysql -uroot -p
```

- docker exec : Ejecuta un comando en un contenedor en ejecución.
- -it : Permite la interacción (interactiva) y asigna un pseudo-TTY.
- mysql-container: Nombre del contenedor que especificaste al crear el contenedor.
- mysql: Llama al cliente de MySQL.
- -uroot : Especifica que te conectas con el usuario root.
- -p: Te pedirá que ingreses la contraseña del usuario root (la que configuraste al crear el contenedor).

## Reiniciar y parar el contenedor

```
# Reiniciar el contenedor
docker start mysql-container

# Parar el contenedor
docker stop mysql-container
```

# PostgreSQL en Docker con persistencia

### Creación del contenedor

```
docker run --name postgres-container -e POSTGRES_PASSWORD=tu_contraseña -e POSTGRES_DB=mi_base_de_datos -v postgres_data
```

- --name postgres-container: Nombre del contenedor.
- -e POSTGRES\_PASSWORD=tu\_contraseña : Establece la contraseña para el usuario postgres.
- -e POSTGRES\_DB=mi\_base\_de\_datos : Crea una base de datos inicial llamada mi base de datos.
- -v postgres\_data:/var/lib/postgresql/data: Crea un volumen llamado postgres\_data para persistir los datos.
- -p 5432:5432 : Expone el puerto 5432 (puerto predeterminado de PostgreSQL) para conectarte desde tu máquina.
- -d postgres:latest : Utiliza la imagen más reciente de PostgreSQL y ejecuta el contenedor en segundo plano.

### Conectarse al contenedor

Es posible conectarse al contenedor vía el cliente psql de PostgreSQL:

```
docker exec -it postgres-container psql -U postgres
```

# Reiniciar y parar el contenedor

```
# Reiniciar el contenedor
docker start postgres-container
# Parar el contenedor
docker stop postgres-container
```

# Referencias

- https://dev.mysql.com/doc/
- https://www.postgresql.org/docs/
- https://wiki.postgresql.org/
- https://roadmap.sh/sql
- https://www.sqltutorial.org/
- https://www.sqlitetutorial.net/
- https://datalemur.com/sql-tutorial
- https://github.com/XD-DENG/SQL-exercise
- https://www.w3schools.com/sql/default.asp
- https://www.sqlzoo.net/wiki/SQL\_Tutorial
- https://sqlbolt.com/
- https://bookdown.org/paranedagarcia/database/sql.html
- https://thedataschools.com/sql/
- https://gestionbasesdatos.readthedocs.io/es/latest/index.html

# Licencia

(cc) BY-SA

Esta obra está bajo una licencia de Creative Commons Reconocimiento-Compartir Igual 4.0 Internacional.